

# 基于计算机视觉的眼底疾病在线实时检测技术项目申请书

## （一）项目简介

根据国家卫生健康委相关数据，我国患有眼底疾病的人数上升速率远高于眼科医生的培养速率，因而患者在眼病初期进行相关检测显得十分重要。然而，常见的前往大型医院进行相关检测的策略存在如开销较大、医疗资源紧张、检测即时性欠缺等问题，不利于眼部疾病的尽早诊断。为此，本项目拟基于计算机视觉的相关知识，结合深度学习的相关技术，建立眼底病变智能诊断神经网络模型，并搭建在线实时诊断系统，最终实现对患者眼底疾病进行在线实时监测的功能，达到有效降低患者检测开销、增强眼底疾病检测便利性的效果，为实现健康中国战略，贡献属于当代大学生的一份力量。

## （二）研究目的

### 1.提高眼底疾病的早期诊断和治疗水平

根据世界卫生组织相关数据，全球约有 3.5 亿人患有眼底疾病，其中包括青光眼、白内障、黄斑变性等疾病。这些疾病在不同年龄阶段都有可能发生，而且患者人数呈现逐年增加的趋势。据悉，传统的眼底检查方法主要依靠医生的经验和眼底图像的观察，存在诊断准确率低、诊断效率低等问题。例如，在中国，约有 60% 的青光眼患者未被及时发现，部分原因是因为诊断存在误差。研究表明，基于计算机视觉的眼底疾病检测技术已经取得了一定的进展，通过图像处理和机器学习算法的结合，可以提高诊断的准确性和效率。例如，有研究表明，通过深度学习技术，可以将青光眼和正常眼底图像的诊断准确率提高至 85.7%。

### 2.减轻医生的工作负担并提高其工作诊断的效率

眼底疾病是一种常见的眼部疾病，但其诊断需要经验丰富的医生，需要通过仔细观察眼底图像来确定病变程度和类型。传统的诊断方法存在诊断不准确、漏诊和误诊等问题，同时医生的数量有限，导致存在检查周期长、费用高等问题。而此项目使用深度学习算法对眼底图像进行自动化分析，可以在短时间内对大量的眼底图像进行筛查，将可能存在的病变图片信息标注出来。这些标注信息可以帮助医生更快地确定患者的病情，并在进一步的检查中更加关注这些区域，提高诊断准确性。例如，在一项针对糖尿病视网膜病变的研究中，基于计算机视觉的技术的诊断准确

率高达 94.5%，而眼科医生的准确率为 86.3%。同时，该项目还将探索利用机器学习算法进行潜在疾病推测的方法，通过分析眼底图像中的多种特征，可以推测出患者潜在的眼部疾病，从而提前预防疾病的发生和防止疾病的恶化，可有效减轻医生工作负担和减少患者医疗费用。传统诊断方法与深度学习方法对比如表 1 所示：

表 1：眼底疾病传统诊断方法与深度学习方法对比

传统诊断方法	深度学习诊断方法
人工经验性诊断，易漏诊误诊	机器学习自动诊断，准确率较高
检查周期较长，医疗费用较高	基于大数据诊断，检查速度快，费用低
人工肉眼观察，预测病情较难	基于大数据分析，标注特征对比，可预测潜在疾病
医疗资源有限，医生工作负担较大	基于深度学习诊断，可缓解医疗资源紧张问题

（三）研究内容

本项目主要包括三部分内容：第一部分为眼底图像数据准备，第二部分为建立眼底病变智能诊断神经网络模型，第三部分是网络云平台 and 线上实时诊断系统的搭建。项目结构如图 1 所示：




图 1：项目内容结构图

各部分具体工作如下：

1. 彩色眼底图、血管 OCT 图像准备

眼底血管作为人体唯一可以无创直接观察的血管，其状况对于眼底疾病的诊断具有极其重要的意义。本项目中视网膜眼底图像参考 ETDRS 标准对 DR 严重程度进行了以下四种划分：正常、NPDR、严重的 NPDR 与非高风险的 PDR 和高风险的 PDR。具体见表 2：

表 2：DR 级别与疾病程度对应关系表

级别	疾病严重程度
正常	无 DR
NPDR	轻度和中度的 NPDR
NPDR2PDR	严重的 NPDR 和非高风险的 PDR
PDR	高风险的 PDR

眼底彩照图像中存在一系列成像噪声，如：采集过程中存在眼底两侧的黑色空间、图像对比度较低、光线不足，模型在成像较差的照片中无法准确识别眼底的微小损伤，会导致最终的识别效果下降。为改善以上情况，可通过将每个图像周边裁切定量像素去除无效黑色区域，减少计算量，提高处理效率。根据采用模型的输入要求，通过图像处理技术，把所有图像缩放到指定大小，再使用自适应直方图均衡化（Adaptive Histogram Equalization,AHE），数学表达式如下：

$$\begin{aligned} f_c(u,v) &= q(u-v,\alpha) - \beta q(u-v,1) + \beta u q(d,\alpha) \\ q(d,\alpha) &= \frac{1}{2} \sin(d) |2d|^\alpha, \end{aligned} \quad \alpha \geq 0 \text{ 且 } \beta \leq 1$$

从而增强图像病变局部对比度，有助于有效提取特征。对于颜色较沈的图像，本实验通过一种对比度缩放的算法增强了各个区域的对比度效果。数学表达式如下：

$$I(x,y) = \frac{I(x,y) - I_{\min}}{I_{\max} - I_{\min}} \times 255$$

其中  $I(x, y)$  为原图像中的各像素灰度值,  $I_{max}, I_{min}$  分别为图像中灰度值的最大值与最小值。

在本项目中, 原数据集 PDR 的数量仅占总数的 8% 左右, 并且 DR 病理特征的级间差异很大。模型比较难以学习 PDR 的特征, 甚至会将其过度识别成 NPDR2PDR。由于原数据中病变样本与正常样本分布极不均衡, 不利于模型进一步学习 PDR 特征。通过数据增强技术, 对图像进行旋转、缩放、翻转, 可以有效减轻数据集中不平衡现象, 也可以一定程度上增强模型的泛化能力。数据预处理图像示例如下。

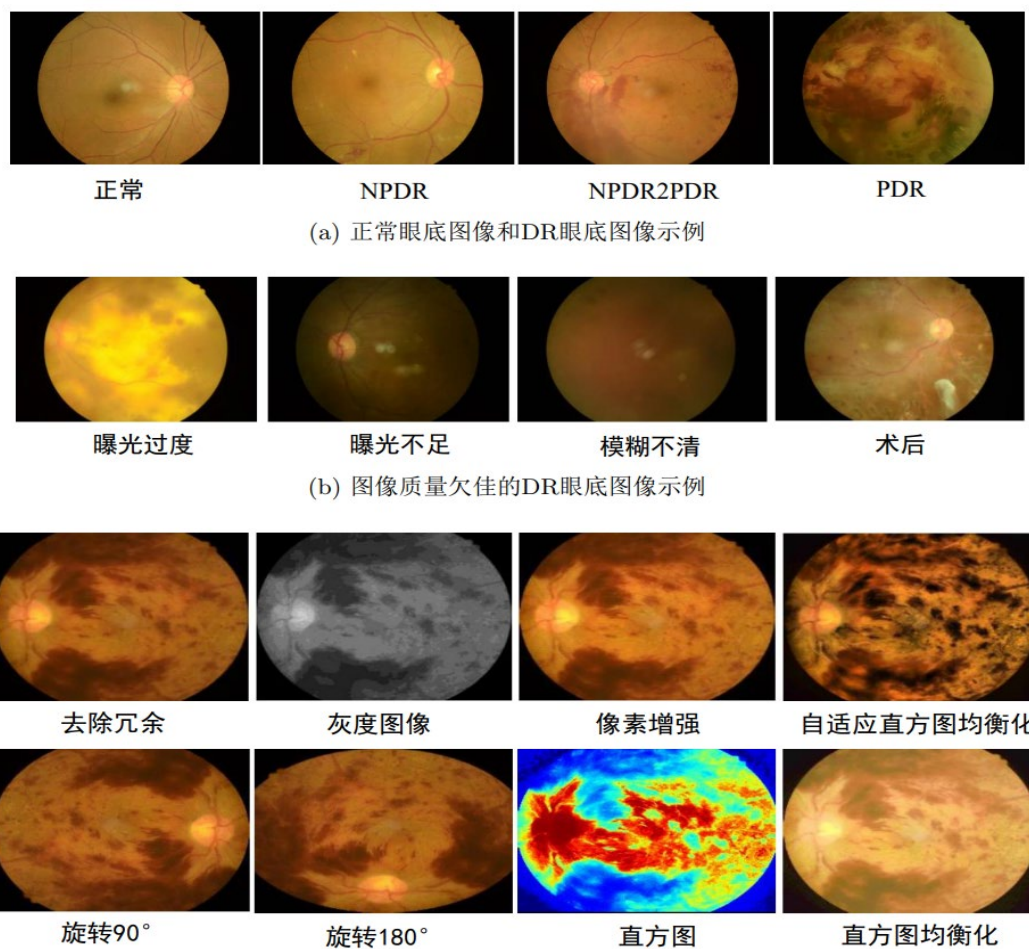


图 2 眼底图像预处理结果

## 2.眼底病变智能诊断神经网络模型的建立

复杂的视网膜结构使得不同病变程度的特征易于混淆, 导致模型的误诊率较高。本项目利用迁移学习在预训练模型上利用本项目的眼部数据集进行针对训练,

从而能够提取有效的特征。该模型分会通过眼底筛查照片进行眼底病变特征提取，判断是否存在病变特征，若存在则进一步评估病变等级，最后提供一份眼底病变报告。

本项目使用的特征提取器有：InceptionV3、InceptionResNetV2 和 Xception，这三种特征提取器都是基于 Inception 架构的深度卷积神经网络模型，已经在 ImageNet 数据集上进行了与训练，取得较高的准确性，迁移到本项目识别任务时也可以获得良好的性能表现。由于视网膜结构的复杂性使得病变特征不易于学习，而上述特征提取器都采用了深度卷积神经网络，并且引入了残差结构，能够充分提取图像中病变特征，进一步减少梯度消失和梯度爆炸。Xception 采用了深度可分离卷积操作，大大减少模型参数量，能够在保持准确率的同时大大提高模型的计算效率。

本项目根据数据分布特点开发了一种标准的深度神经网络模型（Standard Deep Neural Network, SDNN）。SDNN 的输入由特征提取器的输出提供，第一层是全局平均池化层（GAP），第二层是包含 2,048 个隐藏神经元的完全连接层。适当的非线性是提高分类模型性能的重要因素，神经网络中通过引入了激活函数实现了网络的非线性拟合。在本项目中考察了 ReLU 和其变体 LeakyReLU 之间的非线性程度对于 SDNN 网络分类性能表现的影响。实验结果显示，在相同的参数条件下，Leaky ReLU 在缩短模型训练时间和收敛方面明显优于 ReLU 函数。这可能是因为 ReLU 在梯度下降的优化过程中无法对静默状态的神经元进行调整，从而导致训练速度降低，而 LeakyReLU 函数可以对这样的神经元进行细微的调整。因此本项目 SDNN 网络最终选择 LeakyReLU 函数作为激活函数。

ReLU 函数和 LeakyReLU 函数的表达式如下。

$$h^{(i)} = \max(w^{(i)(T)}x, 0) = \begin{cases} w^{(i)T}x, & \text{if } w^{(i)T}x > 0 \\ 0, & \text{otherwise} \end{cases}$$
$$h^{(i)} = \max(w^{(i)(T)}x, 0) = \begin{cases} w^{(i)T}x, & \text{if } w^{(i)T}x > 0 \\ 0.01w^{(i)T}x, & \text{otherwise} \end{cases}$$

在每个全连接层之后添加 Dropout 层，Dropout 层可以通过给定的概率在训练过程中丢弃神经元，可以有效地防止数据过拟合。最后一层是标准的 Softmax 分类器，并采用交叉熵作为损失函数。Softmax 函数将一个任意实值的 N 维向量生成另

一个实值在（0,1）范围内的 N 维向量，且总和为 1。输出 向量的每个值代表样本属于每个类别的概率。交叉熵用以揭示网络的真实标签和预测标签之间的距离或紧密程度，其数学表达式如下：

$$L_j = -\log \left( \frac{e^{s_j}}{\sum_{k=1}^N e^{s_k}} \right)$$

其中，N 表示类别数， $s_j$  为样本标签  $j$  的得分， $s_k$  为特定标签  $k$  的得分。函数 Softmax 确保了预测概率呈现适当的概率分布。SDNN 分类器结构如图 3 所示：




图 3 SDNN 分类器结构

Galton 理论指出，结合多个简单的预测是进行精确预测的动力。在独立训练了基本模型 Xception、InceptionV3、和 InceptionResNetV2 之后，本实验通过平均其 Softmax 值将这三个模型组合成了一个集成模型，控制集成模型的宽度可以基于较弱的学习器获得较好的识别表现。本项目眼底疾病识别模型示意图如图 4 所示：

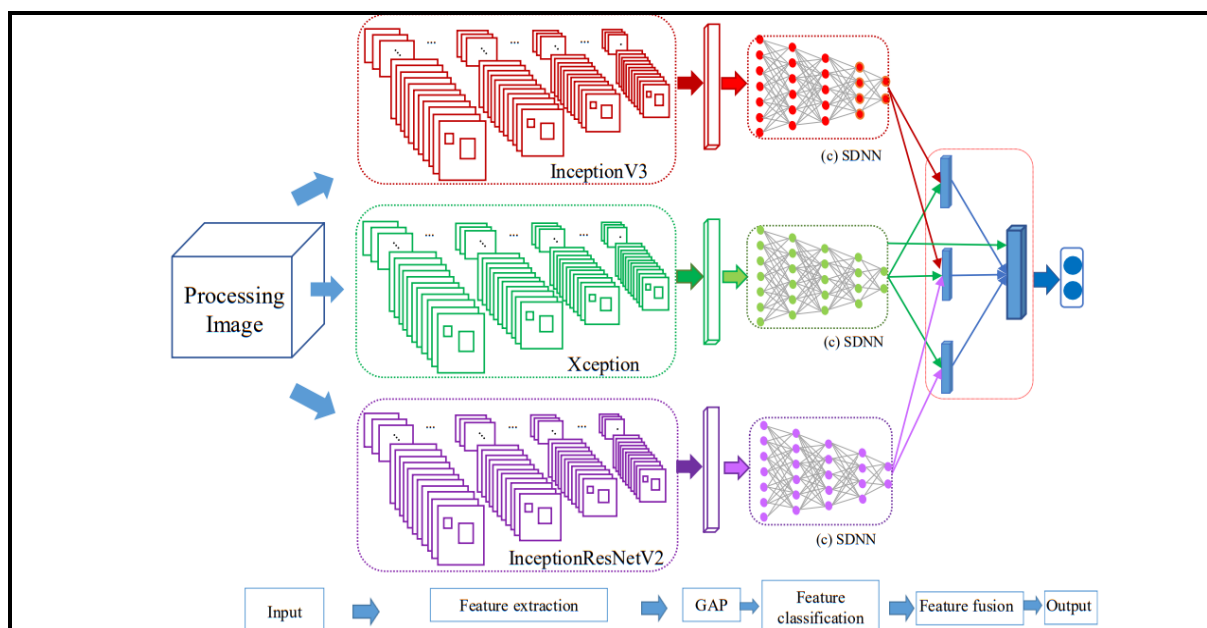


图 4 眼底疾病识别模型

### 3.网络云平台与线上实时诊断系统搭建

基于上述提出的模型，本项目建立了一眼部疾病病变筛查的智能诊断系统，便于患者进行远程定期检查，可以长期、稳定的跟进眼部疾病的发展状况，进而给出适当的建议。为了便于系统的维护和升级以及用户的日常使用，系统架构采用了 Browser/Server 网络模式。将服务端部署在阿里云计算平台上，利用云计算平台强大的算力资源提高系统整体性能表现，并且可以进行数据实时关理和备份，保证数据安全性。

系统整体架构图如图 5 所示：

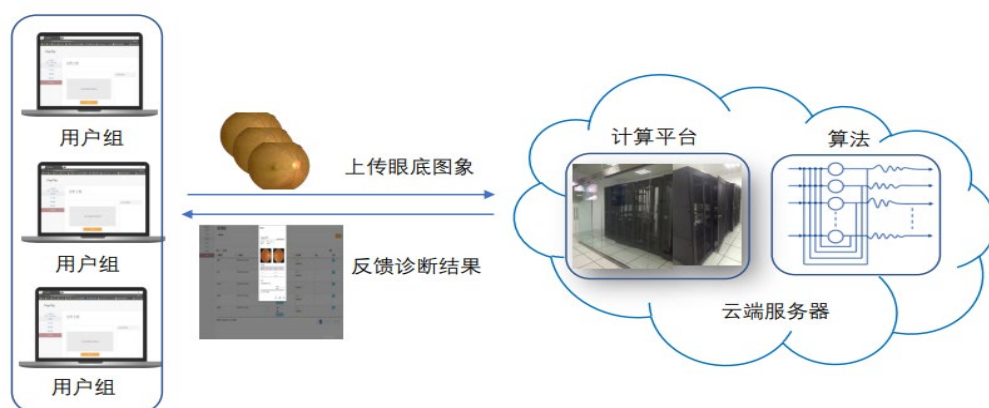


图 5 系统整体架构图



#### （四）国、内外研究现状和发展动态

目前，全球约有 22 亿人患有视力障碍，其中超过 10 亿人患有中度或重度视力障碍或因可预防、可纠正的原因而失明[1]。视力障碍已经成为全球范围内主要的健康问题之一。

引起视力障碍的原因主要是眼底病变，而大部分的眼病可防可控，因此，眼病的早期筛查在防盲治盲工作中意义重大。然而，由于医疗资源分配不均、眼科医疗人才匮乏、医生诊断个体差异较大等因素，大规模有效的人工筛查难以实现。而 AI 与计算机视觉技术的结合，可有效解决眼病早期筛查的肉眼识别图像的个体化差异问题，同时使短时间处理大量图像、搭建远程医疗服务平台成为可能，从而有效推进眼病的早期筛查[2]。

眼科疾病大多具有特征性改变，因此眼科疾病的诊疗高度依赖影像学检查。而光学相干断层扫描 (Optical coherence tomography, OCT) 和眼底照相等影像技术的广泛使用，为 DL 模型开发积累了大量眼底病变相关临床数据。同时，眼科开展人工智能研究具有良好的安全性和推广便利性。这些优势为 DL 模型提供了坚实的数据基础，有利于模型的优化迭代，提高模型性能，实现良性循环。短时间内眼科人工智能研究迅速发展。

##### 1. 相关研究

2016 年 12 月，Google Brain 团队在著名期刊《JAMA》发表研究论文[3]，论文介绍了该团队训练的用于检测糖尿病视网膜病变 (Diabetic Retinopathy, DR) 的深度神经网络。Google Brain 团队利用由 54 名美国注册眼科医生和眼科资深住院医师组成的小组对 128175 张视网膜图像进行了 3 至 7 次分级形成的糖尿病视网膜病变、糖尿病黄斑水肿相关的回顾性发展数据集，对一种特殊类型的神经网络进行了深度卷积神经网络的图像分类优化。最终的算法在检测可参考的糖尿病视网膜病变方面具有高灵敏度和特异性，在眼底照片国际标准 5 分类方面的准确性也不逊于专业眼科医生。随后，在 2017 年 7 月，斯坦福大学 Rishab Gargeya 等学者在眼科权威期刊《Ophthalmology》发表了基于眼底照相深度学习的 DR 智能检测系统的论文[4]。一时间，眼底疾病的计算机辅助诊断引发广泛关注。

国内由中山大学参与研发的基于深度学习用于诊断儿童白内障并提供风险分层和治疗建议的人工智能平台 CC-Cruiser，在真实世界临床环境中表现出良好的诊断效果和强大的治疗决策能力。在一项多中心随机对照试验中，CC-Cruiser 的白内障诊断和治疗确定的准确率分别达到 87.4%和 70.8%，诊断的平均时间为 2.79 分钟，同时取得了高水平的病人满意度[5]，展现出强大的临床应用潜力。

在另一项研究中，Phene 等学者使用 86618 张眼底图像的训练集和 1508 张眼底图像的调整集开发了一个 DL 算法，用于筛查可转诊的青光眼。该算法在一个独立的数据集上有良好的性能，其敏感度高于眼科护理人员，特异性与之相当，AUC 为 0.945[6]。

Ting 等学者根据新加坡综合糖尿病视网膜病变项目的 10 个外部数据集开发并测试了一个临床上可接受的 DRZ 诊断系统，该系统在 6 个不同的国家和地区运行了 5 年，其中包括中国和美国两个人口大国。系统运用的模型敏感度、特异性和 AUC 分别为 90.5%、91.6%和 0.936，在多个民族中实现了高质量的诊疗[7]。

2019 年，Burlina 等学者深入探讨了 DL 算法对老年性黄斑变性（Aged-related macular degeneration, AMD）严重程度的 4 级和 9 级分类的诊断效果，同时使用一个基于 DL 的回归模型估计病人的疾病进展，进一步扩大了 DL 算法的应用范围[8]。

2020 年，Daniel 等学者使用 31262 名受试者的眼底图像及 52 个 AMD 相关遗传变异的数据训练 DL 模型以预测 AMD 的进展。相关试验结果表明，在预测 AMD 的进展方面，结合眼底彩色图像和患者相应的 AMD 基因型的预测结果相比仅通过眼底彩色图像准确性方面有较明显的提高[9]。此次遗传学与 DL 算法的成功结合应用，为后续相关研究提供了新思路。

## 2. 发展中的问题

### (1) 高质量数据获取困难

DL 模型的训练需要大量的高质量数据支持。已经有相关研究表明，在决定 DL 模型的诊断性能方面，各种与数据集中图像有关的因素比技术因素起着更重要的作用[10]。目前大多数眼科领域的人工智能算法使用的都是完全监督的学习模型，要求医生对原始数据进行高标准的数据标注。但获取高标准的此类数据标注属于劳动密

集型的工作且需要耗费大量时间。最终获得的数据标注也因标注标准和标注者水平不同存在较大差异。不仅如此，对于一些罕见的眼病，其发病率低导致相关数据难以收集。以上因素均为 DL 模型的开发带来一定程度的困难。

### (2)训练集的构建缺乏统一标准

DL 模型的训练建立在较大图像集的基础上，其中包含多种类型的图像，如不同眼底照相机、不同视野成像、散瞳与非散瞳图像等。而对数据集中图像的诊断主要依靠经验丰富的眼科医生，诊断结果存在一定差异性。但目前没有标准的训练集，在训练集中缺乏统一的诊断参考标准和解决评分者分歧的方法[11]，这使 DL 模型的训练及后续的诊疗工作受到了较大限制。

### (3)安全问题

为了尽可能实现 DL 模型的高泛化性，模型的训练应在多中心数据集上进行。但由于数据传输中的病人隐私和数据安全问题，研究合作者，特别是国际研究合作者往往受到限制，因此，对来自不同国家的数据管理也是一个重大挑战。

DL 算法的不可解释性也是一个需要关注的问题。现有的 DL 模型的解释方法无法为 DL 模型提供足够的透明度以证明其医疗诊断、治疗决定和风险预测的合理性，导致医务人员无法充分信任 DL 模型，进一步产生新的临床见解。这大大限制了 DL 模型相关成果的实际应用。

## 3. 总结与展望

AI 在眼科中的应用给眼病的大面积筛查带来便捷，能够有效推进眼病的早期筛查，完善相关疾病的一级预防。其在临床诊疗中的应用，不仅能够有效解决医疗资源分配不均的问题，还能大大降低诊疗时间，提高医疗服务质量，缓解医疗机构压力。因此，AI 辅助眼科疾病检测的前景广阔。但由于高质量数据获取困难，算法的不可解释性等因素，相关技术在广泛的临床应用前，仍需做进一步的研究。

## 参考文献

[1] 张炜.眼底疾病智能诊断研究[D].四川大学,2021.DOI:10.27342/d.cnki.gscdu.2021.000041.

[2]王萱,陈向东,刘志敏,欧阳红波.人工智能在眼底病变筛查中的应用进展[J].湖南中医药大学学报,2021,41(12):1975-1980.

[3]Varun Gulshan,Lily Peng,Marc Coram,Martin C. Stumpe,Derek Wu,Arunachalam Narayanaswamy,Subhashini Venugopalan,Kasumi Widner,Tom Madams,Jorge Cuadros,Ramasamy Kim,Rajiv Raman,Philip C. Nelson,Jessica L. Mega,Dale R. Webster. Development and Validation of a Deep Learning Algorithm for Detection of Diabetic Retinopathy in Retinal Fundus Photographs[J]. JAMA,2016,316(22).

[4]Rishab Gargeya,Theodore Leng. Automated Identification of Diabetic Retinopathy Using Deep Learning[J]. Ophthalmology,2017,124(7).

[5]Diagnostic Efficacy and Therapeutic Decision-making Capacity of an Artificial Intelligence Platform for Childhood Cataracts in Eye Clinics: A Multicentre Randomized Controlled Trial[J]. Eclinicalmedicine, 2019.

[6]Phene B S , Mba R , Hammel N , et al. Deep Learning and Glaucoma Specialists[J]. Ophthalmology, 2019, 126(12):1627-1639.

[7]Ting DSW, Cheung CY, Lim G, et al. Development and validation of a deep learning system for diabetic retinopathy and related eye diseases using retinal images from multi-ethnic populations with diabetes. JAMA. Dec 12 2017;318(22):2211–2223.<https://doi.org/10.1001/jama.2017.18152>.

[8]Burlina P M , Joshi N , Pacheco K D , et al. use of deep learning for detailed severity characterization and estimation of 5-year risk among patients with age-related macular degeneration invited commentary supplemental content.

[9]Yan Qi,Weeks Daniel E,Xin Hongyi,Swaroop Anand,Chew Emily Y,Huang Heng,Ding Ying,Chen Wei. Deep-learning-based Prediction of Late Age-Related Macular Degeneration Progression.[J]. Nature machine intelligence,2020,2(2).

[10]Yip Michelle Y T,Lim Gilbert,Lim Zhan Wei,Nguyen Quang D,Chong Crystal C Y,Yu Marco,Bellemo Valentina,Xie Yuchen,Lee Xin Qi,Hamzah Haslina,Ho Jinyi,Tan TienEn,Sabanayagam Charumathi,Grzybowski Andrzej,Tan Gavin S W,Hsu Wynne,Lee Mong Li,Wong Tien Yin,Ting Daniel S W. Technical and imaging factors influencing

performance of deep learning systems for diabetic retinopathy.[J]. NPJ digital medicine,2020,3(1).

[11]余燕,侯银芬,吴昌凡,张鹏飞.人工智能深度学习技术在常见眼病辅助诊断的应用现状和进展[J].眼科新进展,2020,40(04):396-400.DOI:10.13389/j.rao.2020.0092

### （五）创新点与项目特色

本项目针对现有眼部疾病诊疗存在的局限性，进行了以下方面的创新：

#### 1. 数据创新——移动设备助力数据采集

现如今，眼底疾病最基本且有效的筛查方式是眼底照相，但因其仪器体积较大、移动不便，使用场景较为单一，且传统仪器操作门槛较高，普及难度较大。近年来移动便携式设备发展较为迅速，普及程度较高，使用成本较低，便携移动设备推动相关医疗行业发展已成为大势所趋。本项目基于智能手机摄像构建眼部疾病图像数据集，有效简化了医疗数据采集的过程，同时提高了数据收集的效率；此外本项目利用机器图像处理技术对手机移动设备所采集的图像数据进行预处理操作，保证了图像数据集的可训练性和可参考性。为后续深度学习模型的训练和应用提供了更好的数据支持。

#### 2. 方法创新——基于深度学习的眼底病变智能诊断神经网络模型

传统的眼底疾病诊断需要经验丰富的医生仔细观察患者眼底图像来确定病变情况，所以存在着漏诊误诊的现象。同时传统诊断方式存在着成本高、效率低的现象，难以普适性地惠及患者群体。

本项目基于深度学习和机器学习，构建了眼底病变智能诊断神经网络模型。采用基于 CNN 等卷积网络为架构的相关特征提取器对眼底图像特征进行有效提取，此方法不但可以对对象的深度特征进行自动的提取，还能够提取出数据中更为抽象高级的特征，解决了传统特征提取方法尺度单一的缺点。

#### 3. 模式创新——“互联网+”开创医疗新体验

当今传统的医疗模式需要患者线下前往医院就诊，包括疾病诊疗、后期病情跟踪等。由于医院线下现有医疗资源有限，导致许多患者现如今面临看病难、看病贵等诸多问题，近年来随着互联网的飞速发展，智能医疗，智慧医疗逐渐进入大众视

野，“互联网+”推动医疗行业智能化智慧化转型已成为现代医疗发展的必经之路。本项目借助 B/S 网络模式，利用云计算、云服务构建一套眼部疾病的智能诊断系统，可实现患者的长期远程病情筛查跟踪，借助“互联网+”实现患者就医、医生诊断的模式创新，有效缓解医疗资源紧张的问题现状，满足患者对专业医疗资源的需要。

## （六）技术路线、拟解决的问题及预期成果

### 1、技术路线与拟解决的问题

本项目的技术路线主要包括第一阶段的前期准备过程，第二阶段的具体实现过程，和第三阶段收尾过程共三个阶段，三个阶段的具体流程图如图 6 所示：

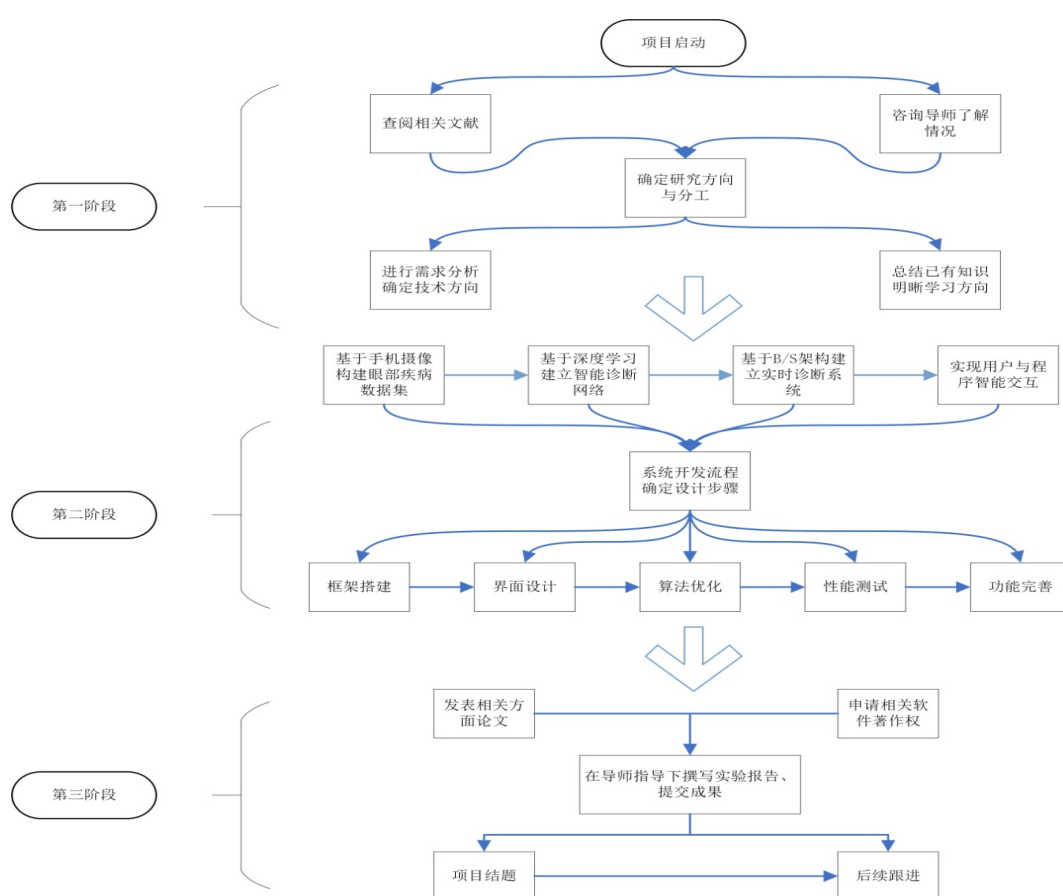


图 6 项目技术路线流程

在技术路线图中，我们对与研究内容相关的部分进行详细说明：

(1) 针对研究内容 3.1，我们计划基于智能手机摄像构建眼部疾病图像数据集。

拟解决的问题：传统眼底照相移动不便、便携仪器价格昂贵、优质眼科医生资源稀缺的问题；智能手机拍摄图像质量层次不齐的问题；开源的智能手机所摄眼部疾病图像数据集稀少的问题

传统筛查眼部疾病最基本和有效的工具是眼底照相，近年来电子照明、非散瞳成像系统和高分辨率数字图像捕捉等方向的进步更是增强了眼底疾病筛查的能力。但传统眼底照相难以克服的缺点在于仪器体积较大、移动不便，来院患者需保持特定姿势才能采集眼底图像，使用场景单一；且仪器需由专业人士进行操作，在基层存在相关人才稀缺，难以普及相关检测的问题。近年来便携式设备的发展弥补了部分传统眼底照相的不足，降低了眼底疾病筛查成本，特别是在人才有限、设备短缺的地区；但依然存在设备需由厂商特制，价格昂贵和牺牲部分图像质量的问题。

与此同时，智能手机在我国的普及明显优于优质眼科医生资源。据中国互联网信息中心（CNNIC）统计，截至 2022 年我国手机网民规模为 10.65 亿，智能手机上搭载的摄像模块已是不可忽视的硬件资源。目前的手机摄像技术可提供高像素、自动对焦、自动曝光的高质量摄影图像，且有高普及率、低门槛的显著优势。相应之下，基于智能手机摄像的眼底照相存在照明质量、手持稳定不足的问题，需要对所拍摄图片进行处理。

因此，我们将结合多种方式形成眼部疾病图像数据集：

①基于开源眼部疾病图像数据集（如 DRIVE、CHASE\_DB1、DIARETDB0、Messidor）。开源数据集已经过相关专业人士标注，可直接用于模型训练和测试；

②医院合作。可以与医院眼科、内分泌科和相关体检中心建立合作关系，遵循数据隐私和保密规定，在与患者签订知情同意书并获取相关单位伦理委员会审批后获取智能手机所拍摄的患者眼底照片；

③数据生成器。机器学习和深度学习的特性决定数据的多样性和数量越大，训练的模型效果越好。因此通过一些技术手段，如镜像翻转、旋转、平移和添加噪声可以有效扩增数据集。

图像数据集建立完毕后进行预处理步骤，如裁剪、缩放、灰度化和标准化等，以便更好地训练和测试模型。

（2）针对研究内容 3.2，我们计划基于机器学习、深度学习建立眼底病变智能诊断神经网络模型。

拟解决的问题：预训练模型性能问题；图片数据库存储方式合理性的问题；训练模型在真实环境的有效性问题

本模型是一个由两部分组成的神经网络，第一部分是将某种预训练模型作为特征提取器，该模型将进行模型权重的初始化；第二部分是一个定制的深度神经网络分类器，将从头开始训练，并基于第一部分所提取的特征进行眼底病变严重程度的预测。

#### 特征提取

考虑到计算速度及内存开销相关因素，我们考察适当的模型架构，如卷积神经网络（CNN），和预训练模型如 ResNet、Inception 等。预训练模型在大规模数据上学习有着优异的特征表示能力，避免从头开始训练模型消耗大量的数据和计算资源。

#### 定制的分类器设计定制的标准深度神经网络

考虑到数据集特点，我们考察各种适合眼底病变分类的深度神经网络结构，如卷积神经网络（CNN）、残差网络（ResNet）、密集连接网络（DenseNet）等，并在训练过程中采用合适的优化器、学习率和正则化技术以避免模型的过拟合和欠拟合问题，同时使用数据增强等技术以增加数据的多样性和数量，提高模型泛化能力。以上步骤以迭代形式进行，需多次尝试并调整模型以获得最佳性能。

在模型训练完成后，我们将对模型进行全方面评估，包括但不限于准确率、召回率、F1 值等，以评估模型的性能和泛化能力，如采用混淆矩阵、ROC 曲线和 AUC 等主流工具分析模型的表现。同时，模型的可解释性、鲁棒性和可部署性等因素也需加以考量，以确保模型能在真实环境中有效工作。

（3）针对研究内容 3.3，我们计划基于 B/S 架构建立实时诊断系统。

拟解决的问题：软件系统架构的合理性问题；服务器在高并发环境下的承载力问题；良好的软件交互，以方便非专业人士使用问题；

C/S 架构（Client/Server）指的是客户端与服务端之间进行数据交互和通信，客户端通常是桌面应用程序或移动应用程序，服务器提供服务端逻辑和数据存储。C/S 架构需要在客户端和服务端分别进行安装和部署。B/S 架构（Browser/Server）指的是通过浏览器访问服务器端应用程序，客户端无需安装应用程序，只需要通过浏览器访问即可。BS 架构的优点在于无需安装和更新客户端，客户端设备的要求也较低。考虑到本眼部病变智能诊断系统特点，我们选择 B/S 架构以降低系统使用门槛，为患者提供实时诊断服务。



基于 B/S 架构的眼部病变智能诊断系统建立需考虑以下步骤：选择云服务器提供商、设计系统架构、代码开发、集成深度学习模型和算法、集成数据库、系统测试和部署、系统监控和维护。

①选择云服务器提供商。主流的云服务器提供商有腾讯云、阿里云、Amazon Web Services (AWS)、Google Cloud、Microsoft Azure 等，考虑到数据安全和系统性能，我们选择阿里云作为系统云服务器。同时，为了保证系统的稳定性和可靠性，我们采用阿里云的 PaaS (Platform as a Service) 服务进行部署，可降低系统的部署和维护成本。

②设计系统架构。根据系统的功能、性能、可靠性、安全性及后续的可拓展性和维护性，我们采用如下的系统架构方案：

1)用户界面层：用户通过浏览器访问网页应用程序，可以进行图像上传、查看和分析诊断结果等操作。这一层采用前端框架 Vue 实现。

2)应用程序层：应用程序层包括系统的逻辑层和数据访问层。逻辑层主要负责业务逻辑和算法实现，数据访问层则负责与数据库进行交互。这一层可以采用 Node.js 技术实现。

3)服务层：服务层包括提供眼部疾病诊断服务的 API 接口和实现实时通信的 WebSocket 服务。API 接口采用 RESTful API 风格，实现可靠、高效的数据传输。WebSocket 服务可以实现服务器主动向客户端推送消息的功能，保证实时性。

4)数据存储层：数据存储层主要负责存储用户上传的眼部图像数据和诊断结果数据。采用关系型数据库（如 MySQL、PostgreSQL）来实现。

5)机器学习层：机器学习层是整个系统的核心，主要负责特征提取、模型训练和预测等任务。这一层采用技术路线（2）中所训练的神经网络。

③开发前后端代码。使用 Web 技术进行代码开发，前端采用 Vue 框架实现交互界面，后端采用 Node.js 技术实现业务逻辑。

④集成深度学习模型和算法：将建立的深度学习模型和算法集成到系统中，提供线上实时诊断服务。

⑤集成数据库：将眼部疾病数据集成到数据库中，提供数据管理和分析服务。

⑥系统测试和部署：对系统进行测试，并根据测试结果进行优化和修改。完成测试后，将系统部署到云平台上。

⑦监控和维护系统：建立监控机制，及时发现和解决系统问题，保证系统的稳定性和可靠性。

## 2、预期成果

(1)构建智能手机所摄眼底病变图片数据集，完成相关特定模型训练，推出对应web 软件，降低传统眼部疾病排查门槛

(2)完成针对低质量图像深度学习相关算法的改进，提供更加便捷的眼部疾病检测服务，并发表高水平论文

(3)完成对 web 交互相关技术的改进，帮助非专业用户轻松使用交互式诊断系统。并发表相关论文

(4)构建易于大众使用的网络云平台与线上实时诊断系统，并申请软件著作权

## （七）项目研究进度安排

(1) 2023 年 3 月-5 月：项目前端页面设计与小程序初步搭建

(2)2023 年 5 月-7 月：眼底病变智能诊断神经网络模型的构建与算法实现

(3)2023 年 7 月-9 月：系统功能优化与实际测试

(4)2023 年 9 月-12 月：进行相关软著、专利申请和高水平论文撰写、投稿

(5)2023 年 12 月-2024 年 3 月：课题报告撰写

## 已有基础

### 1.与本项目有关的研究积累和已取得的成绩

#### (1)研究积累

①项目组成员的加权成绩基本位于专业前 5%，对数字图像处理已经进行了较为深入的探讨和学习，已经完成了大量的前期准备、调研与技术栈的积累；具有良好的研究基础；

②项目组成员参与过具有相似背景的大学生创新训练项目，已经学习了有关医学图像处理的相关知识，对技术的业务背景和需求已经具备较为深入的了解；

③项目组成员通过阅读国内外文献与其他资料，在网上查阅相关内容，对本项目涉及的知识和技术已经有了一定深度的了解；